

OnDokuz Mayıs Üniversitesi

Bilgisayar Mühendisliği Bölümü



Cihan DEMİR

19060428

Makine Öğrenimi Dönem Sonu Projesi

İÇİNDEKİLER

I MATERYAL

1	Veri Önışleme	2
2	Ana Dosya	6

II SONUÇ

3	Sonuç	14
---	-------	----

BÖLÜM: I

MATERYAL

VERİ ÖNİŞLEME

```
import tensorflow as tf
import os
import numpy as np
```

Şekil 1: Veri Önışlemede Kullanılan Modüller

Resimdeki modüller veri önışleme kısmında kullanıldı.

```
dosya_yolu_tavuk = '/content/tavuk'
dosya_yolu_at = '/content/at'
dosya_yolu_kedi = '/content/kedi'
```

Şekil 2: Klasör Yolları

Her bir sınıfa ait olan resimler farklı klasörler içerisinde tutulmuştur ve değişkenlere atanmıştır.

```

def tavuk_veri_seti(dosya_yolu_tavuk, verinin_sinifi):
    # Klasördeki resimler for döngüsü içerisinde okundu.
    for dosya in os.listdir(dosya_yolu_tavuk):
        # Resim okuma
        resim = tf.io.read_file(os.path.join(dosya_yolu_tavuk, dosya))
        # Resmi boyutlandır
        resim = tf.image.decode_jpeg(resim)
        resim = tf.image.resize(resim, (80, 80))
        # Renkli resmi renksiz hale getir
        resim = tf.image.rgb_to_grayscale(resim)
        # Resmi tek boyuta indir
        resim = tf.reshape(resim, (80*80,))
        resim = np.array(resim)
        #Veriyi Etiketle
        resim = np.append(resim, verinin_sinifi)
        # Resim verilerini csv dosyasına yaz
        csv_dosya = 'veri_seti.csv'
        with open(csv_dosya, 'a') as file:
            np.savetxt(file, resim.reshape(-1, resim.shape[-1]), delimiter=',')

tavuk_veri_seti(dosya_yolu_tavuk,0)

```

Şekil 3: Tavuk Veri Setinin Oluşturulması

os modülü kullanılarak dosyaya gidildi. Bir tane görüntü, resim değişkenine atandı. Daha sonra JPEG dosyası 80x80 piksel boyutuna indirildi. Renkli resimli siyah beyaza dönüştürüldü. Bu dönüşüm her piksel değeri için RGB değerlerinin ortalaması alınarak bulundu. Görüntü, 1 boyuta dönüştürüldü ve numpy dizisine çevrildi. Veri etiketleme, her satırın sonuna ilgili görüntünün sınıf numarası eklenerek yapıldı. CSV formatında dosya oluşturulup içine veriler yazdırıldı. Yapılan bu işlemler for döngüsü ile her bir resim için tekrarlandı. Son olarak oluşturulan metoda dosya yolu ve sınıf etiketi verilerek çağrıldı.

```
def at_veri_seti(dosya_yolu_at, verinin_sinifi):
    # Klasördeki resimleri oku
    for dosya in os.listdir(dosya_yolu_at):
        # Resmi oku
        resim = tf.io.read_file(os.path.join(dosya_yolu_at, dosya))
        # Resmi boyutlandır
        resim = tf.image.decode_jpeg(resim)
        resim = tf.image.resize(resim, (80, 80))
        # Renkli resmi renksiz hale getir
        resim = tf.image.rgb_to_grayscale(resim)
        # Resmi tek boyuta indir
        resim = tf.reshape(resim, (80*80,))
        resim = np.array(resim)
        #Veriyi Etiketle
        resim = np.append(resim, verinin_sinifi)
        # Resim verilerini csv dosyasına yaz
        csv_dosya = 'veri_seti.csv'
        with open(csv_dosya, 'a') as file:
            np.savetxt(file, resim.reshape(-1, resim.shape[-1]), delimiter=',')

at_veri_seti(dosya_yolu_at,1)
```

Şekil 4: At Veri Setinin Oluşturulması

Tavuk veri setindeki işlemler, at veri seti için de tekrarlandı. Sadece dosyaya yazma kısmında dosya tekrar oluşturulmadı, var olan dosyanın sonuna eklendi.

```
def kedi_veri_seti(dosya_yolu_kedi, verinin_sinifi):
    # Klasördeki resimleri oku
    for dosya in os.listdir(dosya_yolu_kedi):
        # Resmi oku
        resim = tf.io.read_file(os.path.join(dosya_yolu_kedi, dosya))
        # Resmi boyutlandır
        resim = tf.image.decode_jpeg(resim)
        resim = tf.image.resize(resim, (80, 80))
        # Renkli resmi renksiz hale getir
        resim = tf.image.rgb_to_grayscale(resim)
        # Resmi tek boyuta indir
        resim = tf.reshape(resim, (80*80,))
        resim = np.array(resim)
        #Veriyi Etiketle
        resim = np.append(resim, verinin_sinifi)
        # Resim verilerini csv dosyasına yaz
        csv_dosya = 'veri_seti.csv'
        with open(csv_dosya, 'a') as file:
            np.savetxt(file, resim.reshape(-1, resim.shape[-1]), delimiter=',')

kedi_veri_seti(dosya_yolu_kedi,2)
```

Şekil 5: Kedi Veri Setinin Oluşturulması

Tavuk veri setindeki işlemler, kedi veri seti için de tekrarlandı. Sadece dosyaya yazma kısmında dosya tekrar oluşturulmadı, var olan dosyanın sonuna eklendi.

```
import csv
import numpy as np

# Veri setini oku
with open('veri_seti.csv', 'r') as f:
    oku = csv.reader(f)
    veri = list(oku)

# Veri setindeki her sütun için normalizasyon yap
veri = np.array(veri).astype(float)
for i in range(veri.shape[1]-1):
    sutun = veri[:, i]
    veri[:, i] = (sutun - sutun.min()) / (sutun.max() - sutun.min())

# Normalize edilmiş veriyi yeni bir CSV dosyasına yaz
with open('normalize_veri.csv', 'w', newline='') as f:
    yaz = csv.writer(f)
    for satir in veri:
        # Her hücreyi 4 basamaklı bir sayı olarak formatla
        yeni_satir = ["%.4f" % x for x in satir]
        yaz.writerow(yeni_satir)
```

Şekil 6: Normalizasyon

Veri seti okuma modunda açıldı, csv modülü ile okundu ve liste halinde veri değişkenine atandı. Daha sonra veri değişkenine atanan veriler numpy dizisine dönüştürüldü ve tipleri float olarak belirlendi. Csv dosyasından alınan verilerde sütun sütun gezdirildi ve her sütunun maksimum ve minimum değerleri bulunarak veri setine normalizasyon yapıldı. Daha sonra 'normalize_veri.csv' adındaki yeni dosyaya virgülden sonra 4 basamak olacak şekilde yazdırıldı. 4 basamak yaparak veri setini kullanan algoritmanın işlem yükünü hafifletmek amaçlanmıştır.

ANA DOSYA

Kullanılacak olan modülleri projemize ekliyoruz.

```
1  from random import seed
2  from random import randrange
3  from random import random
4  from csv import reader
5  from math import exp
```

Şekil 7: Kullanılan Modüller

CSV formatında bulunan veri setinden satır satır okuma yapıp veri_seti adındaki listeye ekliyoruz.

```
7  # CSV Dosyasını Yükle
8  def csv_yukle(dosya):
9      veri_seti = list()
10     with open(dosya, 'r') as file:
11         csv_oku = reader(file)
12         for row in csv_oku:
13             if not row:
14                 continue
15             veri_seti.append(row)
16     return veri_seti
```

Şekil 8: Veri Setini İçe Aktarma

Veri setinden string tipinde çekilen verileri float tipine dönüştürüyoruz.

```

19 # Veri Setindeki Değerleri Float Tipine Dönüştür
20 def stringi_floata_donustur(veri_seti, sutun):
21     for satir in veri_seti:
22         satir[sutun] = float(satir[sutun].strip())

```

Şekil 9: Tip Dönüşümü

Her verinin sonunda yer alan etiket değerini float tipinden integerr tipine dönüştürüyoruz.

```

25 # Veri Setindeki Etiket Değerlerini Integer tipine Dönüştür
26 def stringi_inte_donustur(veri_seti, sutun):
27     sinif_degeri = [satir[sutun] for satir in veri_seti]
28     sinif = set(sinif_degeri)
29     tamsayi = dict()
30     for i, deger in enumerate(sinif):
31         tamsayi[deger] = i
32     for satir in veri_seti:
33         satir[sutun] = tamsayi[satir[sutun]]
34     return tamsayi

```

Şekil 10: Tip Dönüşümü

Bu metod ile csv formatındaki dosyadan alınan veriler ile eğitim seti ve test veri seti oluşturuluyor. Kullanıcı tarafından verilen sayıya bölünen veri setinden 1 tanesi test seti olarak ayrılıyor.

```

37 # Veri Setini Belirtilen Sayıya Böler ve 1 Tanesini Test Verisi Olarak Alır
38 def veriyi_bolme(veri_seti, parca_sayisi):
39     bolunmus_veri = list()
40     veri_kopyasi = list(veri_seti)
41     parca_boyutu = int(len(veri_seti) / parca_sayisi)
42     for i in range(parca_sayisi):
43         parca = list()
44         while len(parca) < parca_boyutu:
45             index = randrange(len(veri_kopyasi))
46             parca.append(veri_kopyasi.pop(index))
47         bolunmus_veri.append(parca)
48     return bolunmus_veri

```

Şekil 11: Veriyi Ayırma

Bu metotta tahmin edilen değ er ile ger ek değ erin kar ıla tırılması yapılıp dođruluk y zdesi hesaplanıyor.

```

51  # Doğruluk Y zdesini Hesapla
52  def dogruluk_yuzdesi(gercek, tahmin):
53      dogruluk = 0
54      for i in range(len(gercek)):
55          if gercek[i] == tahmin[i]:
56              dogruluk += 1
57      return dogruluk / float(len(gercek)) * 100.0

```

 ekil 12: Doğruluk Y zdesi

 ekil11'deki metodu kullanarak veri setini test ve eđitim seti olarak ayırır. Kullanılan backpropagation algoritması ile tahmin ger ekle tirir.  ekil12'deki metodu kullanarak dođruluk y zdesini hesaplar. Ba arı oranını geri d nd r r.

```

61  def temel_metod(veri, algoritma, parca_sayisi, *args):
62      bolunmus_veri = veriyi_bolme(veri, parca_sayisi)
63      basari_orani = list()
64      egitim_verisi = list(bolunmus_veri)
65      egitim_verisi.remove(bolunmus_veri[3])
66      egitim_verisi = sum(egitim_verisi, [])
67      test_verisi = list()
68      for i in bolunmus_veri[3]:
69          i_copy = list(i)
70          test_verisi.append(i_copy)
71          i_copy[-1] = 1
72
73      tahmin = algoritma(egitim_verisi, test_verisi, *args)
74      gercek = [i[-1] for i in bolunmus_veri[3]]
75      basari = dogruluk_yuzdesi(gercek, tahmin)
76      basari_orani.append(basari)
77
78      return basari_orani

```

 ekil 13: Temel İşlemler

Kullanılan modelin hesaplanması işlemi bu metotta yapılır.

```

82 def activate(agirlik, girdi):
83     aktivasyon= agirlik[-1]
84     for i in range(len(agirlik) - 1):
85         aktivasyon += agirlik[i] * girdi[i]
86     return aktivasyon

```

Şekil 14: Modelin Hesaplanması

Yapay sinir ağlarında ileri yayılım işlevi bu metod ile yapılır. Girdiler alınır rastgele atanan ağırlıklarla çarpılır, aynı nörona bağlanan ağırlıklar ve girdiler çarpılıp toplanır. Son olarak elimizde bir çıktı değeri oluşur.

```

95 def ileri_yayilim(ag, satir):
96     girdi = satir
97     for katman in ag:
98         yeni_girdi = []
99         for noron in katman:
100             aktivasyon = activate(noron['weights'], girdi)
101             noron['output'] = sigmoid(aktivasyon)
102             yeni_girdi.append(noron['output'])
103         girdi = yeni_girdi
104     return girdi

```

Şekil 15: İleri yayılım

İleri yayılımda her nöronda çıktıları bulmak için kullanılan sigmoid fonksiyonu bu metod ile tanımlanmıştır.

```

89 # Sigmoid Fonksiyonu
90 def sigmoid(aktivasyon):
91     return 1.0 / (1.0 + exp(-aktivasyon))
92

```

Şekil 16: Sigmoid Fonksiyonu

Geri yaymada kullanılacak olan sigmoid fonksiyonunun türevi burada tanımlanmıştır.

```

107 def sigmoid_turev(cikti):
108     return cikti * (1.0 - cikti)
109

```

Şekil 17: Sigmoid Fonksiyonunun Türevi

Bu metotta her katmanda bulunan her nöronun hata bilgisi bulunarak hata_liste adındaki listeye atanıyor.

```

111 def hatayi_yay(ag, gercek_deger):
112     for i in reversed(range(len(ag))):
113         katman = ag[i]
114         hata_liste = list()
115         if i != len(ag)-1:
116             for j in range(len(katman)):
117                 hata = 0.0
118                 for noron in ag[i + 1]:
119                     hata += (noron['weights'][j] * noron['delta'])
120                 hata_liste.append(hata)
121         else:
122             for j in range(len(katman)):
123                 noron = katman[j]
124                 hata_liste.append(noron['output'] - gercek_deger[j])
125             for j in range(len(katman)):
126                 noron = katman[j]
127                 noron['delta'] = hata_liste[j] * sigmoid_turev(noron['output'])
128

```

Şekil 18: Hatayı Geriye Yayma

Şekil17’de kullanılan metod ile bulunan hatalar kullanılarak ağırlık değerlerinin güncellemesi işlemi bu metod ile yapılacaktır.

```

133 def agirlklari_guncelle(ag, satir, alfa):
134     for i in range(len(ag)):
135         girdi = satir[i]
136         if i != 0:
137             girdi = [noron['output'] for noron in ag[i - 1]]
138         for noron in ag[i]:
139             for j in range(len(girdi)):
140                 noron['weights'][j] -= alfa * noron['delta'] * girdi[j]
141                 noron['weights'][-1] -= alfa * noron['delta']

```

Şekil 19: Ağırlıkları Güncelleme

Bu metod ile ağı eğitme işlevini gerçekleştirir. Verilen epoch sayısı kadar dönen bir for'un içinde bir for döngüsü daha kullanılarak eğitim setinden satır satır okuma işlemi yapılır. İçteki for'da ilk olarak ilk veri ile ileri yayılım yapılır. Hatayı geriye yayma işlemi yapılır ve en sonda ağırlıklar güncellenir. Ekrana da epoch sayısı adım adım yazdırılır.

```

144 def train_network(ag, train, alfa, n_epoch, n_outputs):
145     for epoch in range(n_epoch):
146         for satir in train:
147             outputs = ileri_yayilim(ag, satir)
148             expected = [0 for i in range(n_outputs)]
149             expected[satir[-1]] = 1
150             hatayi_yay(ag, expected)
151             agirliklari_guncelle(ag, satir, alfa)
152             print(epoch)

```

Şekil 20: Ağı Eğitme

Kullanılan ağ yapısı burada oluşturulur.ag adında liste oluşturulur. Kullanıcıdan alınan değer kadar gizli katmanda nöron oluşturulur. Çıktı katmanındaki nöron sayısı ise sınıflandırma sayısına eşittir.

```

154 def initialize_network(girdi, g_noron_sayisi, cikti_sayisi):
155     ag = list()
156     gizli_katman = [{'weights':[random() for i in range(girdi + 1)]} for i in range(g_noron_sayisi)]
157     ag.append(gizli_katman)
158     cikti_katmani = [{'weights':[random() for i in range(g_noron_sayisi + 1)]} for i in range(cikti_sayisi)]
159     ag.append(cikti_katmani)
160     return ag

```

Şekil 21: Ağı Oluşturma

İleri yayılım metodunu kullanarak oluşan çıktılarla sınıflandırma yapar.

```

168 def tahmin_et(ag, satir):
169     cikti = ileri_yayilim(ag, satir)
170     return cikti.index(max(cikti))

```

Şekil 22: Sınıflandırma Yapma

Girdi ve çıktı sayısı burada belirlenir. Ağ yapısı burada çağrılır ve oluşturulur. Ağ burada eğitilir. Tahmin metodu burada çağrılarak işlem yapılır.

```

173 def back_propagation(train, test, alfa, epoch, g_noron_sayisi):
174     girdi_sayisi = len(train[0]) - 1
175     cikti_sayisi = len(set([row[-1] for row in train]))
176     ag = initialize_network(girdi_sayisi, g_noron_sayisi, cikti_sayisi)
177     train_network(ag, train, alfa, epoch, cikti_sayisi)
178     tahmin_list = list()
179     for row in test:
180         tahmin = tahmin_et(ag, row)
181         tahmin_list.append(tahmin)
182     return(tahmin_list)

```

Şekil 23: Tahmin Oluşturma

Veri setinin ismi dosya değişkenine atanır. csv_yukle fonksiyonu çağrılarak veri seti uygulamaya yüklenir. For döngüsü içerisinde veri setindeki değerler stringden float'a dönüştürülür. Daha sonra etiket değerleri stringden integer'e dönüştürülür. Veri setinin kaç'a ayrılacağı değeri verilir. Öğrenme değeri alfa değişkenine atanır. Epoch sayısı belirlenir. Gizli katmanda bulunan nöron sayısı verilir. İşlemler sonucunda başarı oranı ekrana yazdırılır.

```

185 dosya = 'normalize_veri.csv'
186 veri_seti = csv_yukle(dosya)
187 for i in range(len(veri_seti[0])-1):
188     stringi_floata_donustur(veri_seti, i)
189     stringi_inte_donustur(veri_seti, len(veri_seti[0])-1)
190 parca_sayisi = 5
191 alfa = 0.5
192 epoch = 1000
193 g_noron_sayisi = 2 |
194 basari_orani = temel_metod(veri_seti, back_propagation, parca_sayisi, alfa, epoch, g_noron_sayisi)
195 print('Başarı Oranı: %s' % basari_orani)

```

Şekil 24: Değerler

BÖLÜM: II

SONUÇ

SONUÇ

Model için at,tavuk ve kedi veri kümeleri kullanıldı. Her veri kümesinde 300 adet jpeg formatında görüntü bulunmaktadır.

Veri kümelerinde görüntüyü boyutlandırma, görüntüyü renksiz hale getirme ve etiketleme işlemleri yapılmıştır.

Model resim boyut kadar girdi, 2 nöronlu gizli katman ve 3 tane nöron bulanan çıkış katmanına sahiptir.

Sonuç olarak yapılan 6 denemede %45.8'lik bir doğruluk oranı sağlanmıştır.

Denemede kullanılan değerler ve sonuçları tabloda verilmiştir.

Görüntü Sınıflandırma					
Deneme Sayısı	Parça Sayısı	Alfa	Epoch	Gizli Nöron Sayısı	Başarı Oranı
1	5	0.5	2200	2	%50
2	4	0.5	2200	2	%45
3	4	0.5	1000	2	%42
4	4	0.5	4000	2	%45
5	4	0.5	3000	2	%47
6	4	0.5	2500	2	%46